

Welche Cluster sind biologisch sinnvoll?

K-means, hierarchisches Clustering und Leiden

20.000

lebende PBMCs

37

biologische Marker

20

Spender · je 1.000 Zellen

Ein guter geometrischer Score ist noch kein Nachweis eines Zelltyps.

Eigene Analyse: Notebook 03_clustering, Lauf vom 07.09.2026. PBMC = mononukleäre Zellen des peripheren Bluts.

Gleiche Daten, drei Methodenfamilien

Vorverarbeitung

1.000 PBMCs je Spender, Seed 42



$\operatorname{arcsinh}(x/5)$



Z-Standardisierung je Marker



X : 20.000 Zellen $\times$ 37 Marker

44 Konfigurationen

- K-means: 7 Werte für k , je 10 Starts.
- Hierarchisch: Single, Average, Complete und Ward; je 7 Werte für k .
- Leiden: 3 Nachbarzahlen $\times$ 3 Resolutionen; gewichteter Graph aus X .

$k \in \{2, 3, 4, 6, 8, 10, 12\}$

$n \in \{10, 30, 60\}$; $r \in \{0,3; 0,7; 1,2\}$

Auswahl je Methode: kleinster Davies–Bouldin-Index unter den Lösungen mit Stabilität $\geq 0,6$.

Stabilität: 10 Wiederholungen mit je 80 % der Zellen pro Spender; Skalierung und Clustering erneut fitten. Details in Reservefolie 10.

Die Auswahl liefert sehr unterschiedliche Lösungen

Methode	Parameter	Cluster	DB ↓	Stabilität	Größtes Cluster
K-means	$k = 4$	4	2,363	0,995	37,780 %
Single	$k = 2$	2	0,264	1,000	99,995 %
Average	$k = 2$	2	0,894	0,602	99,975 %
Complete	$k = 2$	2	0,948	0,617	99,960 %
Ward	$k = 6$	6	2,522	0,611	38,220 %
Leiden	$n = 30, r = 1,2$	18	2,361	0,683	17,940 %

K-means und Leiden: ähnliche DB-Werte, unterschiedliche Auflösung und Stabilität.

Clustergrößen mitlesen: Single, Average und Complete bündeln jeweils über 99,9 % der Zellen.

DB = Davies–Bouldin-Index, kleiner ist besser. Stabilität = ungewichteter Mittelwert der Cluster-Median-Jaccards. Eigene Notebook-Ergebnisse.

Warum der beste DB-Wert hier täuscht

Single Linkage, $k = 2$

19.999

Zellen in C0

1

Zelle in C1



99,995 % der Zellen in einem Cluster

Trotzdem ausgezeichnete Kennzahlen

DB: 0,264

Stabilität: 1,000


Die Trennung eines isolierten Events kann geometrisch günstig und beim Resampling reproduzierbar sein.

Diese Lösung trennt hauptsächlich einen Ausreißer ab; sie beantwortet die Frage nach Zelltypen nicht.

Balken zeigt den Anteil der großen Gruppe; die einzelne Zelle ist maßstabsgetreu nicht sichtbar. Eigene Ergebnisse; DB-Definition: scikit-learn.


K-means gruppiert grob, Leiden teilt finer auf

K-means · 4 Cluster



3.148–7.556 Zellen pro Cluster
Mittlere Stabilität: **0,995**

Leiden · 18 Cluster




223–3.588 Zellen pro Cluster
Mittlere Stabilität: **0,683**

Die feinere Aufteilung liefert Kandidaten für Untergruppen, deren Stabilität einzeln geprüft werden muss.

Original-UMAPs aus dem Notebook, Legenden für die Gegenüberstellung ausgeblendet. Gleiche Einbettung; Farben sind je Methode lokal. Clustering und Scores verwenden alle 37 Marker, nicht UMAP.

Der Mittelwert verdeckt instabile Cluster



Leiden: 4 von 18 unter 0,6

C15 und C16 liegen nur bei 0,111 und 0,120.

Ward: 3 von 6 unter 0,6

Die Konfiguration bleibt mit Mittelwert 0,611 zugelassen.

Die Grenze 0,6 gilt für den Mittelwert der Konfiguration, nicht für jeden einzelnen Cluster.

Jeder Punkt: ein Cluster der ausgewählten Lösung. Gespeicherte Median-Jaccards; die gestrichelte Linie dient zum Vergleich der Einzelwerte.

Markerprofile liefern biologische Hypothesen

Hypothese	K-means	Leiden	Einordnung
B-Zell-artig	C0: CD19↑, HLA-DR↑, CD3↓	C3: CD19↑, HLA-DR↑, CD3↓	Ähnliche relative Profile
NK-Zell-artig	C3: NKp46↑, CD94↑	C4: NKp46↑, CD122↑, CD3↓	Kandidaten; weitere Marker prüfen
Unklar	C1: CD34↑, CD33↑; C2: CD127↑	Weitere Untergruppen	Profile reichen zur Zuordnung nicht aus

Pfeile beschreiben relative Cluster-Mediane.

Keine Positiv-/Negativ-Gates und kein Nachweis der Koexpression in einzelnen Zellen.

Die Profile stützen Zelltyp-Hypothesen, ersetzen aber keine validierte Zuordnung.

Eigene, vorläufige Interpretation der Notebook-Profile. Biologischer Kontext: Horowitz et al. (2013), doi:10.1126/scitranslmed.3006702. Ähnliche Profile belegen keine Übereinstimmung der Zellmengen.

Unsere Bewertung: robuste Grobstruktur, offene Zelltypen

K-means als grobe Ausgangslösung

Vier sehr stabile Gruppen; plausible Markerprofile für einen Teil der Cluster.

Leiden für feinere Hypothesen

Mehr Untergruppen, darunter mehrere instabile Cluster. Kein pauschaler biologischer Vorteil.

Für die biologische Entscheidung

- Markerkombinationen und Koexpression prüfen.
- Verteilung je Spender und Aufnahmetag kontrollieren.
- Neue Ausgangsstichproben untersuchen, besonders für kleine Gruppen.

Single, Average und Complete sind in der ausgewählten Form stark degeneriert; Ward ist weniger stabil.

Quantitative Bewertung und Markerinterpretation gemeinsam nutzen. Ein eindeutiger biologischer Sieger ist noch nicht belegt.

Bewertung der ausgewählten Lösungen auf dieser Stichprobe; keine allgemeine Rangfolge der Algorithmen.

Reserve: Was ändert sich gegenüber 200 Zellen je Spender?

Methode	200 Zellen/Spender	1.000 Zellen/Spender
K-means	$k = 4$; Stabilität 0,973	$k = 4$; Stabilität 0,995
Single / Average / Complete	jeweils $k = 4$	jeweils $k = 2$
Ward	keine zugelassene Konfiguration	$k = 6$; Stabilität 0,611
Leiden	$n = 30$, $r = 0,7$; 8 Cluster	$n = 30$, $r = 1,2$; 18 Cluster

Zwei Änderungen gleichzeitig:

- Fünfmal so viele Zellen: 4.000 → 20.000 insgesamt.
- Zusätzlich $k = 2$ und $k = 3$ im Raster der distanzbasierten Verfahren.

Die Unterschiede können nicht allein der größeren Stichprobe zugeschrieben werden.

200er-Referenz: geprüfter Neulauf mit Grenze 0,6, nicht die früheren veralteten Notebook-Ausgaben. Quellen: beide Untersuchungsberichte im Repository.

Reserve: Wie wird Stabilität berechnet?

Für Wiederholung b werden dieselben behaltenen Zell-IDs R_b verglichen:

$$J_{c,b} = \max_j \frac{|(C_c \cap R_b) \cap D_{j,b}|}{|(C_c \cap R_b) \cup D_{j,b}|}, \quad S = \frac{1}{K} \sum_{c=1}^K \text{median}_b J_{c,b}.$$

C_c : ursprünglicher Cluster; $D_{j,b}$: neuer Cluster auf den behaltenen Zellen.

- 10 Wiederholungen, jeweils 80 % innerhalb jedes Spenders ohne Zurücklegen.
- Skalierung und Clustering neu fitten; Methodenparameter bleiben gleich.
- Abwesende Cluster: NaN. Mindestens 6 auswertbare Wiederholungen im aktuellen Lauf.
- Keine Mindestgröße; ein Singleton kann beim Behalten stabil sein.

Gemessen wird Robustheit innerhalb der Ausgangsstichprobe, nicht Übertragbarkeit auf neue Spender.

Eigene Notebook-Implementierung; Referenzzuordnungen sind keine Ground Truth.

Reserve: Quellen und Reproduzierbarkeit

Eigene Ergebnisse

notebooks/03_clustering.ipynb, Lauf vom 07.09.2026.

20.000 Zellen, Seed 42, Arcsinh-Cofaktor 5, Z-Standardisierung; 44 + 440 Fits.

Tabellen und UMAPs direkt aus den gespeicherten Notebook-Ausgaben exportiert.

Datensatz und biologischer Kontext

Horowitz et al. (2013). Genetic and environmental determinants of human NK cell diversity revealed by mass cytometry. *Science Translational Medicine*.

[doi:10.1126/scitranslmed.3006702](https://doi.org/10.1126/scitranslmed.3006702)

Arvaniti & Claassen (2017). Sensitive detection of rare disease-associated cell subsets via representation learning. *Nature Communications*.

[doi:10.1038/ncomms14825](https://doi.org/10.1038/ncomms14825)

Methodendokumentation

scikit-learn: [Davies–Bouldin-Index](#) SciPy: [Linkage](#) Scanpy: [Leiden](#)